SUPERVISED LEARNING - REGRESSION

LINEAR REGRESSION: MEMPREDIKSI NILAI KONTINU DENGAN GARIS LURUS

Metode statistik dasar untuk memodelkan hubungan antara variabel independen (fitur) dan variabel dependen (target) numerik.

1. APA ITU & UNTUK APA? (THE CONCEPT & PROBLEM)

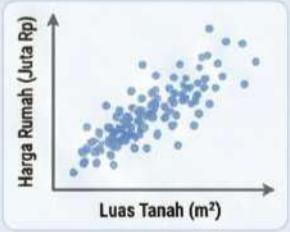

DATA & TANTANGAN (Pola Tersembunyi)

Kita punya data historis, tapi bagaimana memprediksi harga untuk luas tanah yang belum pernah ada datanya?

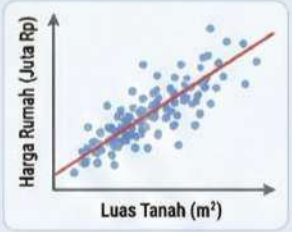

SOLUSI (Garis Prediksi)

Cari garis lurus "terbaik" yang mewakili tren data untuk melakukan prediksi.

2. PERSAMAAN MODEL (THE EQUATION)

$$y = b_0 + b_1 * x \ (+ \varepsilon)$$

Target/ Dependen
Nilai yang ingin diprediksi (misal: Harga Rumah).

Fitur/ Independen
Data masukan yang digunakan (misal: Luas Tanah).

Intercept/ Bias
Titik potong garis dengan sumbu Y (nilai y saat x=0).

Slope/ Koefisien
Kemiringan garis. Seberapa besar y berubah untuk setiap perubahan 1 unit x.

Error/ Residual
Kesalahan acak yang tidak bisa dijelaskan oleh model (noise).

3. MENCARI GARIS "TERBAIK" (THE OPTIMIZATION)

FUNGSI BIAYA (Cost Function - MSE)

Konsep & Visual

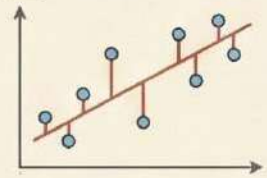

$$MSE = \frac{1}{n}\sum_{i}^{n}(y_i - \hat{y}_i)^2$$

Hitung rata-rata kuadrat dari semua kesalahan (jarak vertikal). Tujuan: **MINIMALKAN** nilai ini.

GRADIENT DESCENT (Algoritma Optimisasi)

Konsep & Visual

Secara iteratif sesuaikan b_0 dan b_1 untuk menuruni "lembah kesalahan" hingga menemukan titik terendah (garis optimal).

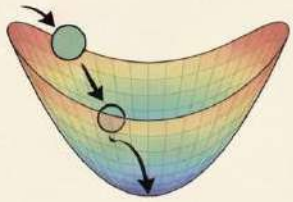

4. EVALUASI MODEL (THE METRICS)

R-squared (R^2)

$$1 - \frac{MSE_{\text{model}}}{MSE_{\text{baseline}}}$$

Seberapa baik garis menjelaskan variasi data. Nilai mendekati 1 semakin baik (e.g., 0.85 = 85% variasi dijelaskan).

RMSE (Root Mean Squared Error)

$$\sqrt{MSE}$$

Rata-rata besar kesalahan dalam satuan asli target. Semakin kecil semakin baik.

5. CONTOH PENERAPAN SPESIFIK (USE CASE: PREDIKSI HARGA RUMAH)

Masalah: Agen properti ingin mengestimasi harga jual rumah berdasarkan luasnya. →

Data: Kumpulkan data historis 1000 transaksi (Luas m², Harga Jual). →

Proses: Latih model Linear Regression (**Harga = b_0 + b_1 * Luas**) →

Hasil: Didapat persamaan **Harga (Juta) = 150 + 5 * Luas (m²)** →

Aplikasi: Untuk rumah 100m², prediksi harganya adalah **150 + 5*100 = 650 Juta**

RESIDUALS (ERROR): DIAGNOSTIK KINERJA MODEL PREDIKSI

Selisih antara nilai aktual dan nilai prediksi, kunci untuk mengevaluasi dan memperbaiki model machine learning.

1. APA ITU RESIDUAL? (THE CONCEPT & FORMULA)

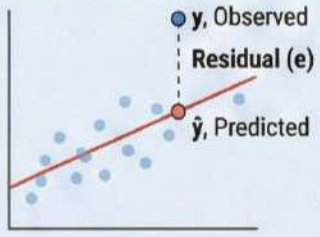

$$e = y - \hat{y}$$

(Observed - Predicted)

Jarak vertikal antara data asli dan garis prediksi model. Positif jika prediksi terlalu rendah, negatif jika terlalu tinggi.

2. MENGAPA PENTING? (THE DIAGNOSTICS)

Evaluasi Kinerja

Mengukur seberapa baik model "pas" dengan data.

Cek Asumsi Model

Memastikan data memenuhi syarat algoritma (e.g., Linieritas).

Deteksi Masalah

Menemukan outlier atau pola yang terlewat oleh model.

3. ANALISIS POLA RESIDUAL (THE PATTERNS)

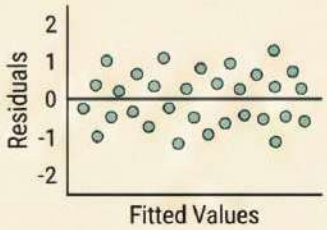

IDEAL (Random Scatter)

Model bagus. Asumsi terpenuhi (Linier, Homoskedastisitas).

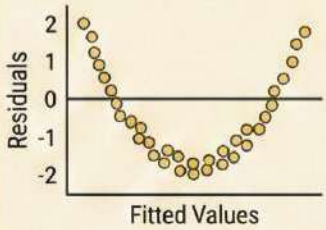

NON-LINIER (Polan Melengkung)

Model linier tidak cukup. Ada hubungan non-linier yang terlewat.

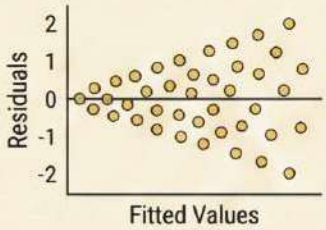

HETEROSKEDASTISITAS (Bentuk Corong)

Varians error tidak konstan. Perlu transformasi data.

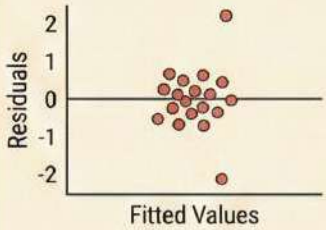

OUTLIER (Titik Ekstrem)

Data anomali yang bisa merusak model.

4. METRIK KUNCI BERBASIS RESIDUAL (THE METRICS)

MSE (Mean Squared Error)

χ^2 $\frac{1}{n}\sum(e_i)^2$

Rata-rata kuadrat error. Menghukum kesalahan besar lebih berat.

RMSE (Root MSE)

$\sqrt{\ }$ $\sqrt{MSE}$

Akar MSE. Dalam satuan asli target, lebih mudah diinterpretasi.

MAE (Mean Absolute Error)

$|\times|$ $\frac{1}{n}\sum|e_i|$

Rata-rata nilai absolut error. Lebih tahan terhadap outlier.

5. CONTOH PENERAPAN SPESIFIK (USE CASE: PREDIKSI HARGA RUMAH)

Masalah: Model regresi linier untuk harga rumah memiliki RMSE tinggi. → **Analisis:** Plot Residual vs. Fitted menunjukkan pola melengkung (Non-linier). → **Tindakan:** Tambahkan fitur polinomial (Misal: Luas²) atau gunakan model non-linier (Random Forest). → **Hasil:** Pola residual menjadi acak, RMSE turun signifikan, prediksi lebih akurat.

MULTIPLE LINEAR REGRESSION: PREDIKSI MULTI-VARIABEL

Perluasan dari regresi linier sederhana yang menggunakan lebih dari satu variabel independen (fitur) untuk memprediksi satu variabel dependen (target) numerik.

1. KONSEP DASAR & PERLUASAN (FROM SIMPLE TO MULTIPLE)

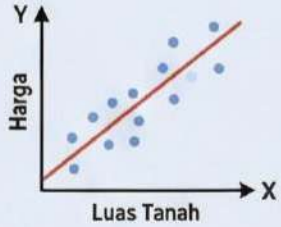

SIMPLE REGRESSION (1 Fitur)

Satu fitur, satu target. Model adalah **GARIS LURUS** ($y = b_0 + b_1x$).

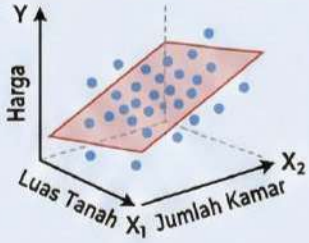

MULTIPLE REGRESSION (Banyak Fitur)

Banyak fitur, satu target. Model adalah **BIDANG DATAR (HYPERPLANE)** dalam ruang n-dimensi.

2. PERSAMAAN MODEL UMUM (THE GENERAL EQUATION)

$$y = b_0 + b_1x_1 + b_2, x_2, \ldots, b_n + \ldots + x_1, x_2, \ldots, x_n + \varepsilon$$

Target/Dependen
Nilai numerik yang ingin diprediksi (e.g., Harga Rumah).

Intercept/Bias
Nilai prediksi saat semua fitur adalah 0.

Koefisien/Bobot
Kontribusi/pengaruh masing-masing fitur terhadap target (setelah fitur lain dianggap tetap).

Fitur/Independen
Data masukan (e.g., Luas, Kamar, Usia Bangunan).

Error/Residual
Kesalahan acak yang tidak dijelaskan model (noise).

3. OPTIMISASI: MENCARI BIDANG "TERBAIK" (*FINDING THE BEST FIT*)

FUNGSI BIAYA
(Cost Function - MSE)

Konsep & Visual

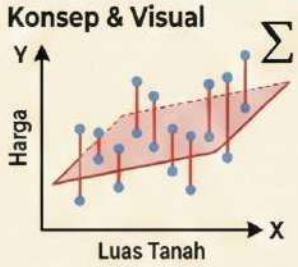

Formula:

$$\text{MSE} = \frac{1}{n}\sum_{n}^{n}(y_i - \hat{y}_i)^2$$

Hitung rata-rata kuadrat jarak vertikal (error) dari semua data ke bidang prediksi.

Tujuan: **MINIMALKAN** total error ini.

GRADIENT DESCENT
(Algoritma Optimisasi Multi-Dimensi)

Konsep & Visual

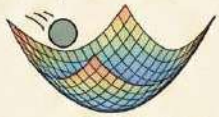

Menyesuaikan **SEMUA** koefisien (b_i) secara iteratif untuk menuruni permukaan error menuju solusi optimal.

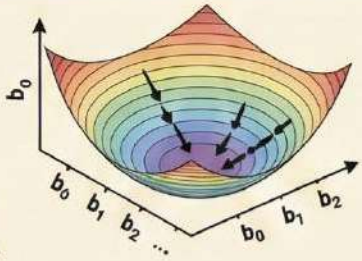

4. ASUMSI & EVALUASI MODEL (*CRITICAL CHECKS & METRICS*)

Asumsi Kunci (Wajib Cek!)

- ☑ **Linieritas:** Hubungan fitur-target harus linier (Cek: Scatter plot residual)
- ☑ **Homoskedastisitas:** Varians error konstan (Cek: Plot Residual vs Fitted, bentuk corong = masalah)
- ☑ **Tidak Ada Multikolinearitas:** Fitur tidak boleh berkorelasi kuat satu sama lain (Cek: VIF - Variance Inflation Factor)
- ☑ **Normalitas Residual:** Error berdistribusi normal (Cek: QQ-Plot / Histogram residual)

Metrik Evaluasi Utama

☑ **R-squared (R^2)**

$$1 - \frac{\text{MSE}_{\text{model}}}{\text{MSE}_{\text{baseline}}}$$

Persentase variasi target yang dijelaskan model. Bisa naik walau fitur baru tidak berguna.

☑ **Adjusted R-squared**

$$1 - \frac{(1-R^2)(n-1)}{(n-p-1)}$$

Versi koreksi R^2 yang menghukum penambahan fitur tidak relevan. Lebih baik untuk Multiple Regression.

5. CONTOH PENERAPAN SPESIFIK (*USE CASE: PREDIKSI HARGA RUMAH LENGKAP*)

Masalah:
Agen properti ingin model harga yang lebih akurat menggunakan banyak faktor.

→

Data:
Kumpulkan data 5000 transaksi dengan fitur: Luas (x_1), Kamar (x_2), Usia (x_3), Lokasi (x_4...), Harga Jual (y).

→

Proses:
Latih Multiple Linear Regression (Harga = $b_0 + b_1$*Luas + b_2*Kamar + b_3*Usia + ...)

→

Hasil:
Persamaan

Harga (Juta) = 100 + 4*Luas + 50*Kamar - 2*Usia

→

Aplikasi:
Rumah 120m², 3 Kamar, Usia 10thn. Prediksi = 100 + 4(120) + 50(3) - 2(10) = 100 + 480 + 150 - 20 = 710 Juta

POLYNOMIAL REGRESSION: MEMODELKAN HUBUNGAN NON-LINIER

Teknik memperluas regresi linier untuk menangkap pola data yang melengkung atau kompleks dengan menambahkan fitur berpangkat.

1. MENGAPA GARIS LURUS TIDAK CUKUP? (THE PROBLEM)

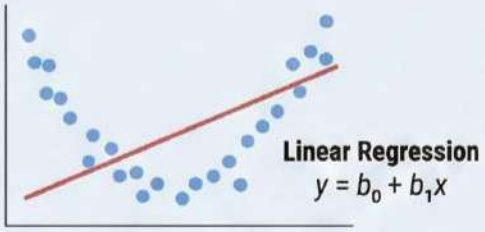

Banyak fenomena tidak mengikuti garis lurus (misal: pertumbuhan, dosis obat). Model linier sederhana gagal menangkap pola lengkung ini (*Underfitting*).

→

2. KONSEP DASAR (TRANSFORMASI FITUR)

Linear (Garis)

$y = b_0 + b_1x$

Hanya menggunakan fitur asli (x).

Polynomial (Kurva)

$y = b_0 + b_1x + b_2x^2 + ... + b_dx^d$

Menambahkan **pangkat** dari fitur asli (x^2, x^3, ...) sebagai fitur baru untuk membentuk kurva.

$x \longrightarrow [x, x^2, x^3]$

↓

3. MEKANISME KERJA: FEATURE ENGINEERING + REGRESI LINIER

$$\begin{bmatrix} x_i \\ \vdots \\ x_i \end{bmatrix} \rightarrow \begin{bmatrix} x_i \\ \vdots \\ x_i \end{bmatrix} \rightarrow \begin{bmatrix} x_i \\ (x_i)^2 \\ (x_i)^3 \\ \dots \end{bmatrix} \rightarrow \begin{bmatrix} x_i \\ \vdots \\ x_i \end{bmatrix} = \begin{bmatrix} x_i & x_3 \\ (x_i)^2 & (x_i)^2 \\ (x_i)^3 & (x_i)^3 \\ \dots & \dots \end{bmatrix} \rightarrow$$

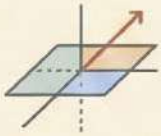

1. Data Asli (X) → **2. Polynomial Transform (Derajat d)** → **3. Data Baru Diperluas (X_poly)** → **4. Standard Linear Regression**

Model regresi linier biasa dilatih pada data yang *sudah ditransformasi*. Kurva yang dihasilkan adalah kombinasi linier dari fitur-fitur non-linier ini.

↓

4. KOMPLEKSITAS & OVERFITTING (MEMILIH DERAJAT "d")

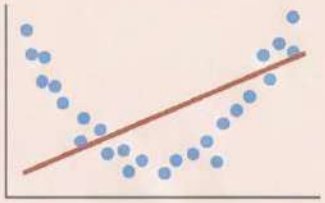

d=1 (Underfitting)
Terlalu sederhana, melewatkan pola.

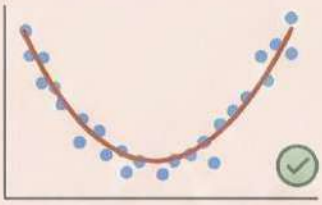

d=2 atau 3 (Good Fit)
Seimbang, menangkap sinyal.

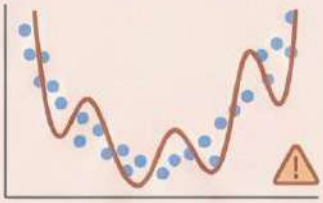

d=15 (Overfitting)
Terlalu kompleks, menghafal noise.

Derajat `d` adalah hyperparameter krusial. `d` terlalu tinggi menyebabkan model menangkap noise, bukan pola (*Overfitting*).

5. CONTOH PENERAPAN SPESIFIK (USE CASE: PREDIKSI GAJI VS PENGALAMAN)

Masalah: Memprediksi gaji berdasarkan tahun pengalaman. Hubungan seringkali melengkung (naik cepat lalu melambat). → **Data:** Scatter plot Gaji vs Pengalaman menunjukkan kurva "S" atau parabola. → **Proses:** Gunakan Polynomial Regression dengan d=2 atau d=3. → **Hasil:** Model kurva (**Gaji = b_0 + b_1*Pengalaman + b_2*Pengalaman²**) menangkap pola kenaikan non-linier jauh lebih akurat daripada garis lurus.

BIAS-VARIANCE TRADEOFF: MENYEIMBANGKAN KESALAHAN MODEL UNTUK PERFORMA OPTIMAL

Visualisasi kompromi antara kesalahan sistematik (bias) dan sensitivitas terhadap data (variance) untuk mencapai model terbaik.

1. KONSEP INTI: MENGAPA INI PENTING? (THE CORE CONCEPT & PROBLEM)

BIAS (Akurasi Rata-rata)

Seberapa jauh rata-rata prediksi model dari nilai sebenarnya.

Bias TINGGI = Model terlalu sederhana, melewatkan pola **(Underfitting)**.

VARIANCE (Konsistensi/Sebaran)

Seberapa sensitif prediksi model terhadap perubahan data latih.

Variance TINGGI = Model terlalu kompleks, menghafal noise **(Overfitting)**.

TOTAL ERROR = BIAS^2 + VARIANCE + IRREDUCIBLE ERROR

2. DEKOMPOSISI TOTAL ERROR (THE DECOMPOSITION)

Bias^2 (Kesalahan Sistematik) + **Variance** (Sensitivitas Data) + **Irreducible Error** (Noise Alami)

Menurun saat model makin kompleks (lebih fleksibel).

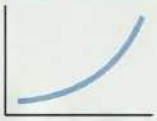

Meningkat saat model makin kompleks (lebih "menghafal").

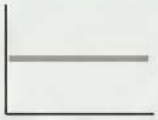

Kesalahan yang tidak bisa dihilangkan, berasal dari data itu sendiri.

Total Error (Jumlah)

Penjumlahan ketiga komponen. Tujuan kita adalah menemukan titik minimumnya.

3. KURVA TRADEOFF & TITIK OPTIMAL (THE SWEET SPOT)

UNDERFITTING
(Bias Tinggi, Var Rendah)

Model terlalu kaku.

Solusi: Tambah kompleksitas, fitur baru.

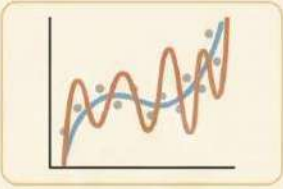

OVERFITTING
(Bias Rendah, Var Tinggi)

Model terlalu fleksibel.

Solusi: Kurangi kompleksitas, regularisasi, tambah data.

4. CONTOH PENERAPAN SPESIFIK (USE CASE: POLYNOMIAL REGRESSION)

Masalah: Memodelkan hubungan non-linier data.

→ **Pilihan Model:** Polynomial Regression dengan berbagai derajat 'd'.

→ **Analisis Tradeoff:** Model d=1 (Garis Lurus) -> Underfitting (Bias Tinggi). Model d=15 (Kurva Sangat Wiggly) -> Overfitting (Variance Tinggi).

→ **Solusi Optimal:** Pilih derajat 'd' di "Sweet Spot" kurva Total Error (misal d=3) yang menyeimbangkan kedua error.

→ **Hasil:** Model yang menangkap pola utama tanpa terpengaruh noise berlebihan.

LASSO REGRESSION (L1): REGULARISASI & SELEKSI FITUR OTOMATIS

Metode regresi yang menambahkan "penalti nilai mutlak" pada koefisien untuk mencegah *overfitting* dan menghasilkan model yang lebih sederhana dengan menonaktifkan fitur yang tidak penting.

1. MASALAH & SOLUSI: KOMPLEKSITAS & FITUR BERLEBIH (THE PROBLEM & SOLUTION)

MASALAH (Overfitting & Banyak Fitur Tidak Relevan)

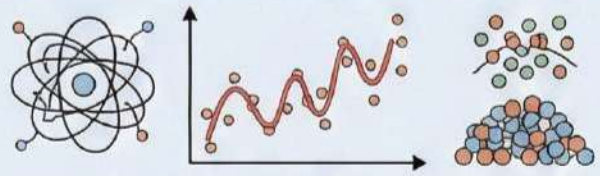

Model terlalu kompleks, menangkap noise dari banyak fitur yang tidak relevan, performa buruk pada data baru.

SOLUSI (Lasso Regression - L1)

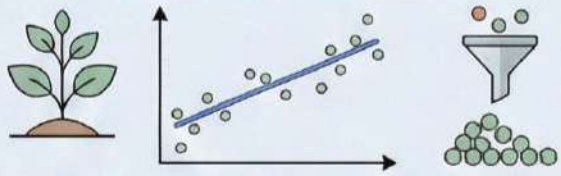

Menambahkan penalti untuk menyederhanakan model dan secara otomatis ***memilih*** fitur penting (koefisien fitur lain jadi nol).

2. MEKANISME KERJA: FUNGSI BIAYA TERMODIFIKASI (THE MECHANISM - L1 PENALTY)

$$Cost_{Lasso} = MSE + \lambda * \sum |b_i|$$

Mean Squared Error
Fungsi biaya asli Regresi Linier (Fit to Data).

Plus Sign
Menambahkan suku baru.

Lambda - Hyperparameter
Kekuatan regularisasi. Mengontrol besar penalti. (0 = Regresi Biasa, Besar = Banyak Fitur Nol).

L1 Penalty Term
Jumlah ***nilai mutlak*** dari semua koefisien (bobot). Penalti ini "memaksa" koefisien menjadi **TEPAT NOL.**

Tujuan: Meminimalkan MSE (agar pas dengan data) **DAN** meminimalkan $\sum|b_i|$ (agar model sparse/jarang) secara bersamaan.

3. FITUR UTAMA: SPARSITY & SELEKSI FITUR (THE KEY FEATURE - ZEROING OUT)

L1 (Lasso) - Wajik (Diamond)

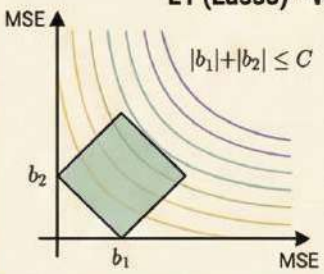

Wilayah kendala L1 memiliki sudut tajam di sumbu. Solusi optimal seringkali "menabrak" sudut ini, membuat koefisien menjadi **TEPAT NOL (Sparsity).**

L2 (Ridge) - Lingkaran (Circle)

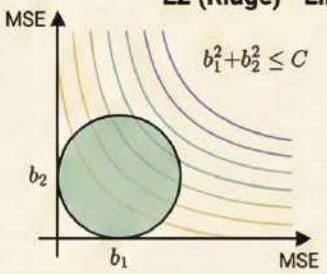

(Bandingkan dengan Ridge) Wilayah kendala L2 halus. Solusi optimal hanya ***mendekati*** nol, jarang tepat nol.

4. PERAN HYPERPARAMETER λ (THE TUNING)

λ = 0 (No Penalty)

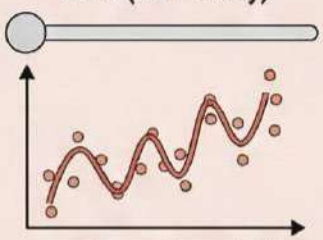

Sama dengan Regresi Linier Biasa. Risiko **Overfitting** tinggi. Semua fitur aktif.

λ Optimal (Balanced)

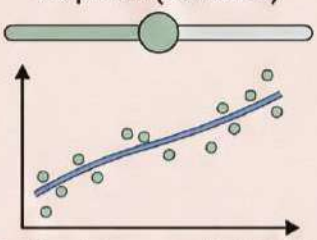

Keseimbangan terbaik. Seleksi fitur efektif, generalisasi baik.

λ Besar (High Penalty)

Hampir semua koefisien (kecuali bias) jadi NOL. Risiko **Underfitting** tinggi (model terlalu sederhana).

5. CONTOH PENERAPAN SPESIFIK (USE CASE: ANALISIS GENETIKA/TEKS DENGAN RIBUAN FITUR)

Masalah: Prediksi risiko penyakit dari data genetika dengan 10.000+ gen (fitur), tapi hanya sedikit yang relevan. → **Data:** Dataset dengan n (sampel) < p (fitur). Banyak noise. → **Proses:** Latih model Lasso Regression dengan tuning λ menggunakan Cross-Validation. → **Hasil:** Model akhir yang sparse (jarang). Hanya puluhan gen penting yang memiliki koefisien tidak nol. Model mudah diinterpretasi dan lebih akurat.

RIDGE REGRESSION (L2): REGULARISASI UNTUK MENCEGAH OVERFITTING

Metode perbaikan regresi linier dengan menambahkan "penalti kuadrat" pada koefisien model untuk meningkatkan generalisasi.

1. MASALAH & SOLUSI: KOMPLEKSITAS & MULTIKOLINEARITAS (THE PROBLEM & SOLUTION)

MASALAH (Overfitting & Multikolinearitas)

Model terlalu kompleks atau fitur sangat berkorelasi (multikolinearitas) menyebabkan koefisien besar dan tidak stabil.

Model menghafal noise, performa buruk pada data baru.

SOLUSI (Ridge Regression - L2)

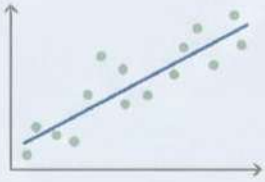

Menambahkan "penalti" untuk mengecilkan koefisien.

Hasilnya model lebih sederhana, stabil, dan lebih baik dalam generalisasi.

2. MEKANISME KERJA: FUNGSI BIAYA TERMODIFIKASI (THE MECHANISM - L2 PENALTY)

$$Cost_{Ridge} = MSE + \lambda * \sum(b_i^2)$$

MSE (Mean Squared Error)
Fungsi biaya asli Regresi Linier (Fit to Data).

Plus Sign
Menambahkan suku baru.

Lambda - Hyperparameter
Kekuatan regularisasi.
Mengontrol seberapa besar penalti.
(0 = Regresi Biasa, ∞ = Koefisien Nol).

L2 Penalty Term
Jumlah kuadrat dari semua koefisien (bobot) model.
Penalti ini "memaksa" koefisien menjadi kecil, tapi **TIDAK PERNAH** benar-benar nol.

Tujuan: Meminimalkan MSE (agar pas dengan data) **DAN** meminimalkan $\sum(b_i^2)$ (agar model sederhana) secara bersamaan.

3. PERAN HYPERPARAMETER λ (THE TUNING)

λ = 0 (No Penalty)

Sama dengan Regresi Linier Biasa.
Risiko **Overfitting** tinggi.

λ Optimal (Balanced)

Keseimbangan terbaik antara Bias dan Variance. Generalisasi optimal.

λ Besar (High Penalty)

Koefisien sangat kecil (mendekati 0).
Risiko **Underfitting** tinggi (model terlalu sederhana).

Nilai λ harus dicari melalui proses **tuning** (misal: Cross-Validation).

4. PERBANDINGAN L1 (LASSO) VS L2 (RIDGE) (THE COMPARISON)

Fitur	L1 (Lasso)	L2 (Ridge)
Jenis Penalti	Nilai Mutlak $\sum\lvert b_i\rvert$	Kuadrat $\sum(b_i^2)$
Efek pada Koefisien	Bisa menjadi **TEPAT NOL** (Sparsity)	Mengecil mendekati nol (Shrinkage), tapi **TIDAK PERNAH** nol
Seleksi Fitur?	**YA** (Otomatis)	**TIDAK** (Semua fitur tetap ada)
Solusi Unik?	Tidak Selalu	**YA** (Selalu)

Gunakan **Ridge** jika Anda ingin mempertahankan semua fitur tapi mengurangi dampaknya (terutama saat ada multikolinearitas).
Gunakan **Lasso** jika ingin seleksi fitur otomatis.

5. CONTOH PENERAPAN SPESIFIK (USE CASE: PREDIKSI HARGA RUMAH DENGAN BANYAK FITUR)

Masalah: Prediksi harga rumah dengan 100+ fitur (misal: jumlah keran, jenis gagang pintu, dll.) yang banyak berkorelasi. → **Data:** Dataset dengan banyak fitur (p) dan jumlah sampel (n) yang relatif sedikit (p ≈ n). → **Proses:** Latih model Ridge Regression dengan tuning λ menggunakan Cross-Validation. → **Hasil:** Koefisien untuk fitur yang kurang penting atau sangat berkorelasi dikecilkan secara signifikan, tapi tidak dihapus. Model akhir lebih stabil dan akurat pada data uji baru dibandingkan Regresi Linier biasa.

ELASTIC NET REGRESSION: KESEIMBANGAN TERBAIK ANTARA LASSO & RIDGE

Metode regularisasi hibrida yang menggabungkan penalti L1 (Lasso) dan L2 (Ridge) untuk seleksi fitur yang stabil dan penanganan multikolinearitas.

1. MASALAH & SOLUSI: KETERBATASAN LASSO & RIDGE (THE LIMITATIONS & THE FIX)

LASSO (L1) - Wajik

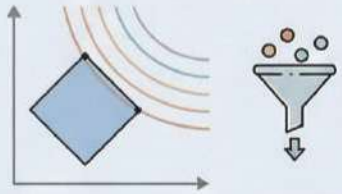

Seleksi fitur otomatis (koefisien nol), **TAPI** cenderung memilih hanya satu variabel dari kelompok yang sangat berkorelasi dan mengabaikan sisanya. Tidak stabil jika p > n.

RIDGE (L2) - Lingkaran

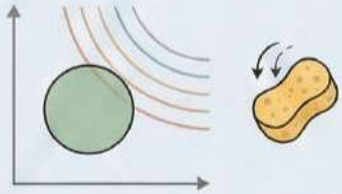

Menangani multikolinearitas dengan baik (mengecilkan koefisien bersamaan), **TAPI** tidak melakukan seleksi fitur (semua fitur tetap ada). Model tetap kompleks.

ELASTIC NET - Hibrida

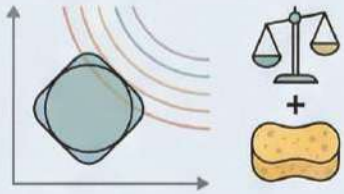

Menggabungkan keduanya: Melakukan seleksi fitur (L1) **DAN** menangani fitur berkorelasi secara grup (L2). Solusi jalan tengah yang robust.

2. MEKANISME KERJA: FUNGSI BIAYA GABUNGAN (THE MECHANISM - HYBRID PENALTY)

$$Cost_{ElasticNet} = \text{MSE} + \lambda \cdot \left[\alpha \cdot \sum |b_i| + \frac{(1-\alpha)}{2} \sum_{i}^{b^2} b_i^2 \right]$$

MSE
Fit to Data (Seperti Regresi Biasa).

Lambda
Kekuatan Regularisasi Total. Mengontrol seberapa besar pengaruh kedua penalti.

Bagian Lasso
Mendorong sparsity (koefisien nol) untuk seleksi fitur. Dikontrol oleh α.

Bagian Ridge
Mendorong koefisien kecil dan berkelompok. Dikontrol oleh (1-α).

Tujuan: Meminimalkan error **DAN** kombinasi tertimbang dari penalti L1 & L2 secara bersamaan.

3. PERAN HYPERPARAMETER λ & α (THE TUNING KNOBS)

λ (Lambda) - Kekuatan Total

λ = 0
(No Regularization)

λ Besar
(High Regularization)

Mengatur keseimbangan antara bias (underfitting).

α (Alpha / l1_ratio) - Keseimbangan L1 vs L2

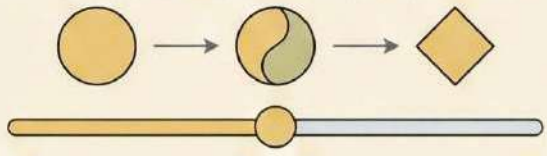

α = 0
(Pure Ridge - L2)

0 < α < 1
(Elastic Net - Mix)

α = 1
(Pure Lasso - L1)

Mengatur proporsi campuran. α=0.5 adalah campuran seimbang. Perlu dituning (misal: Cross-Validation).

4. KEUNGGULAN UTAMA: GROUPING EFFECT (THE KEY BENEFIT)

Perilaku Lasso pada Fitur Berkorelasi

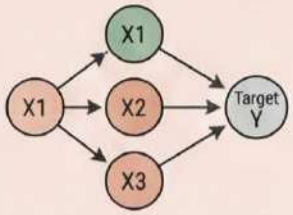

Lasso cenderung memilih satu fitur secara acak dari grup berkorelasi dan membuang yang lain.

Perilaku Elastic Net pada Fitur Berkorelasi

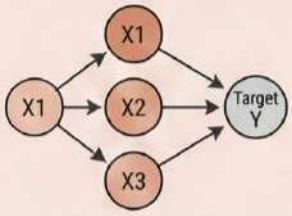

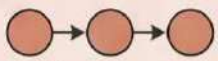

Elastic Net cenderung memilih (atau membuang) seluruh grup fitur berkorelasi sekaligus. "Grouping Effect" ini memberikan model yang lebih stabil dan interpretatif.

5. CONTOH PENERAPAN SPESIFIK (USE CASE: ANALISIS GENOMIK / BIOINFORMATIKA)

Masalah: Prediksi penyakit dari data ekspresi ribuan gen (p >> n) di mana banyak gen bekerja dalam jalur yang sama (sangat berkorelasi).

→

Data: Dataset "high-dimensional" dengan multikolinearitas tinggi.

→

Proses: Latih model Elastic Net, tuning λ dan α dengan Cross-Validation untuk menemukan keseimbangan optimal.

→

Hasil: Model yang sparse (hanya gen penting yang dipilih) TAPI tetap mempertahankan kelompok gen yang berkorelasi (pathway) bersama-sama, memberikan wawasan biologis yang lebih baik daripada Lasso atau Ridge saja.

ROBUST REGRESSION: REGRESI TAHAN OUTLIER UNTUK DATA NYATA

Metode regresi yang dirancang untuk tetap akurat dan stabil meskipun terdapat data ekstrem (outlier) yang menggangu.

1. MASALAH: KELEMAHAN REGRESI LINIER BIASA (OLS) TERHADAP OUTLIER (THE PROBLEM)

OLS (Ordinary Least Squares) - Sensitif

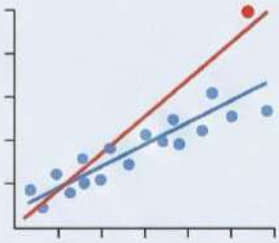

OLS meminimalkan kuadrat error (MSE). Error besar dari outlier diberi bobot sangat besar, menarik garis dan merusak model.

ROBUST REGRESSION - Tahan (Robust)

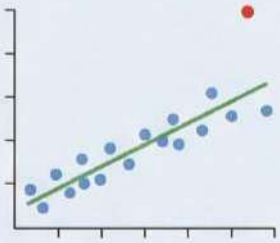

Metode robust dirancang untuk mengurangi atau mengabaikan pengaruh data ekstrem, menghasilkan model yang lebih representatif untuk mayoritas data.

2. MEKANISME KERJA: FUNGSI BIAYA TAHAN BANTING (THE MECHANISM - ROBUST LOSS FUNCTIONS)

Squared Error (OLS - Tidak Robust)

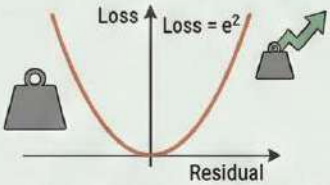

Memberi penalti sangat besar pada error besar (outlier). Sensitif.

Huber Loss (Hybrid - Robust)

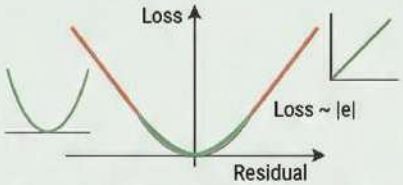

Kombinasi: Efisien untuk error kecil, tidak terlalu menghukum error besar. Kurang sensitif.

Tukey's Biweight (Redescending - Sangat Robust)

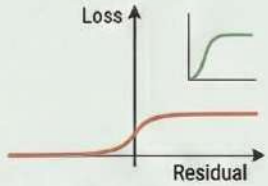

Benar-benar mengabaikan outlier ekstrem setelah batas tertentu. Sangat tahan banting.

3. ALGORITMA ROBUST POPULER (THE ALGORITHMS)

RANSAC (Random Sample Consensus)

1. Pilih Subset Acak Kecil
2. Fit Model ke Subset
3. Hitung Inliers (Data yang Pas)
4. Ulangi & Pilih Model dengan Inliers Terbanyak

Iteratif: Mencoba banyak model pada sampel acak dan memilih yang paling konsisten dengan mayoritas data (inliers).

Theil-Sen Estimator (Median-based)

1. Hitung Slope (Kemiringan) untuk SEMUA Pasangan Titik
2. Ambil MEDIAN dari Semua Slope
3. Gunakan Median Slope untuk Model Akhir

Non-parametrik: Menggunakan median kemiringan antar pasangan titik. Sangat tahan terhadap outlier (hingga ~29%).

4. CONTOH PENERAPAN SPESIFIK (USE CASE: PREDIKSI HARGA PROPERTI DENGAN DATA ERROR)

Masalah: Prediksi harga rumah dari data publik yang mengandung input error (misal: harga 10x lipat karena typo, atau properti super mewah).

→ **Data**: Dataset dengan beberapa outlier ekstrem.

→ **Proses:** Gunakan Robust Regression (misal: Huber Regressor atau RANSAC) alih-alih OLS biasa.

→ **Hasil**: Model yang dihasilkan tidak terpengaruh oleh segelintir data error/ekstrem, memberikan prediksi yang lebih akurat dan dapat diandalkan untuk pasar properti umum.

POISSON REGRESSION: MEMODELKAN DATA CACAH (COUNT DATA)

Teknik regresi untuk variabel dependen yang berupa bilangan bulat non-negatif (cacahan) dengan asumsi distribusi Poisson.

1. APA ITU DATA CACAH? (THE CONCEPT)

Contoh:
Jumlah Kunjungan Harian,
Jumlah Komplain,
Jumlah Kejadian

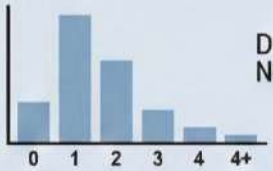

Distribusi Diskrit, Non-Negatif

Variabel target (Y) adalah hitungan kejadian dalam interval waktu/ruang tertentu. Bukan kontinu.

2. MENGAPA BUKAN REGRESI LINIER? (THE PROBLEM)

Regresi Linier

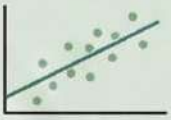

Prediksi Negatif (Tidak Masuk Akal)

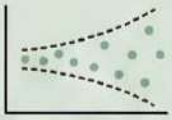

Varian Tidak Konstan

Tantangan Data Cacah

Harus Non-Negatif

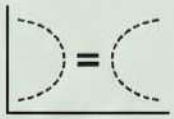

Asumsi:
Varian = Mean (λ)

Regresi linier melanggar asumsi dasar data cacah, menghasilkan prediksi yang bias dan tidak valid.

3. MODEL POISSON & FUNGSI LINK (THE MECHANISM)

Prediktor Linier (X)

$$\eta = \beta_0 + \beta_1 x_1 + \ldots + \beta_p x_p$$

Fungsi Link: log(μ) = η

Laju Kejadian / Mean (μ)

$$\mu = \exp(\beta_0 + \beta_1 x_1 + \ldots + \beta_p x_p)$$
$$= \exp(\beta_0) * \exp(\beta_1 x_1) * \ldots$$

Fungsi link logaritma natural (log) menghubungkan prediktor linier dengan rata-rata kejadian (μ), menjamin prediksi selalu positif.

4. INTERPRETASI KOEFISIEN (THE MEANING)

$x_i = 0$ → $\mu_0 = \exp(\beta_0)$

+1 Unit x_i →

$x_i = 1$ → $\mu_1 = \exp(\beta_0 + \beta_i) = \mu_0 * \exp(\beta_i)$

$$\times \exp(\beta_i)$$

Setiap peningkatan 1 unit pada x_i, laju kejadian (μ) dikalikan dengan faktor **exp(β_i)**. Ini adalah **efek multiplikatif**, bukan aditif.

5. FITTING & TANTANGAN (ESTIMATION & ISSUES)

Maximum Likelihood Estimation - MLE

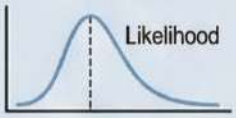

Cari β yang Memaksimalkan Likelihood

Metode estimasi parameter (**β**) yang paling umum digunakan.

Overdispersion

Jika Varian > Mean, gunakan **Negative Binomial Regression** sebagai alternatif.

6. CONTOH PENERAPAN SPESIFIK (USE CASE: JUMLAH KECELAKAAN LALU LINTAS)

Masalah:
Memprediksi jumlah kecelakaan per bulan di berbagai ruas jalan.

→

Data:
Variabel dependen (Y) = Jumlah Kecelakaan (Count).
Variabel independen (X) = Volume Kendaraan, Kondisi Jalan, Cuaca.

→

Model:
Poisson Regression.

→

Hasil:
exp(**β**_volume) = 1.05 artinya setiap kenaikan 1000 kendaraan, laju kecelakaan diperkirakan meningkat 5% (dikalikan 1.05), dengan faktor lain tetap.